

LAPORAN PROYEK

Implementasi *Case-Based Reasoning* (CBR) untuk Retrieval dan Prediksi Putusan Kasus Penghinaan, Fitnah, dan Pencemaran Nama Baik Menggunakan TF-IDF dan IndoBERT

Disusun untuk memenuhi tugas Mata Kuliah Penalaran Komputer



Dosen Pengampu:

Ir. Galih Wasis Wicaksono, S.Kom., M.Cs.

Disusun oleh:

RICHA CINTA SARI (202310370311262)

RADHIYA ASTIFA (202310370311281)

Program Studi Informatika

Fakultas Teknik

Universitas Muhammadiyah Malang

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi telah menghasilkan pertumbuhan data hukum digital yang sangat masif, terutama dalam bentuk putusan pengadilan yang dipublikasikan secara terbuka oleh Mahkamah Agung Republik Indonesia melalui Direktori Putusan (putusan3.mahkamahagung.go.id). Per tahun 2025, direktori tersebut telah memuat lebih dari 10 juta dokumen putusan dari berbagai tingkatan pengadilan di seluruh Indonesia. Pertumbuhan yang sangat pesat ini menyebabkan proses pencarian dan analisis putusan serupa menjadi semakin sulit apabila dilakukan secara manual oleh praktisi hukum maupun masyarakat umum.

Dalam praktik hukum Indonesia, putusan terdahulu memiliki peran penting sebagai referensi dalam penyelesaian perkara baru. Hakim, jaksa, advokat, maupun akademisi hukum sering memanfaatkan putusan sebelumnya untuk memahami pola pertimbangan hukum, penggunaan pasal, serta kecenderungan amar putusan pada kasus yang memiliki karakteristik serupa. Akan tetapi, dengan jumlah putusan yang terus bertambah setiap harinya, kebutuhan akan sistem otomatis untuk pencarian dan analisis kasus menjadi sangat mendesak.

Pendekatan kecerdasan buatan (Artificial Intelligence), khususnya Case-Based Reasoning (CBR), menawarkan solusi yang relevan terhadap permasalahan tersebut. CBR merupakan paradigma penalaran berbasis kasus yang memanfaatkan pengalaman masa lalu untuk membantu menyelesaikan masalah baru yang serupa. Aamodt dan Plaza (1994) mendefinisikan CBR sebagai pendekatan pemecahan masalah yang bekerja melalui siklus Retrieve-Reuse-Revise-Retain, di mana sistem mencari kasus terdahulu yang paling mirip (retrieve), menggunakan solusinya sebagai acuan (reuse), merevisi solusi bila diperlukan (revise), dan menyimpan kasus baru yang sudah terselesaikan ke dalam basis kasus (retain).

Pada penelitian ini, metode CBR diterapkan pada domain hukum pidana, khususnya perkara penghinaan, fitnah, dan pencemaran nama baik yang diatur dalam Pasal 310 KUHP (penghinaan), Pasal 311 KUHP (fitnah), dan Pasal 315

KUHP (penghinaan ringan). Domain ini dipilih karena memiliki karakteristik fakta hukum yang relatif serupa antar kasus, namun tetap membutuhkan analisis mendalam terhadap konteks dan pertimbangan hukum yang digunakan dalam putusan. Selain itu, perkara dalam domain ini cukup banyak ditemukan di Direktori MA RI sehingga memungkinkan pengumpulan data yang memadai.

Untuk melakukan pencarian kemiripan kasus, penelitian ini menggunakan dan membandingkan dua pendekatan representasi teks yang berbeda. Pertama, TF-IDF (Term Frequency-Inverse Document Frequency) dikombinasikan dengan Cosine Similarity sebagai pendekatan statistik berbasis frekuensi kata yang sederhana, efisien, dan mudah diimplementasikan. Kedua, IndoBERT (indobenchmark/indobert-base-p1) sebagai model transformer berbahasa Indonesia yang dikembangkan oleh Wilie et al. (2020) melalui proyek IndoNLU, yang mampu menangkap makna semantik teks hukum berbahasa Indonesia secara lebih mendalam. Perbandingan kedua pendekatan ini diharapkan memberikan gambaran yang komprehensif mengenai kelebihan dan keterbatasan masing-masing metode pada domain hukum dengan dataset terbatas.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana cara membangun basis kasus (case base) hukum yang terstruktur menggunakan dokumen putusan Mahkamah Agung pada domain perkara penghinaan, fitnah, dan pencemaran nama baik?
2. Bagaimana cara merepresentasikan setiap kasus putusan ke dalam format terstruktur yang dapat diproses secara komputasional menggunakan metode CBR?
3. Bagaimana performa TF-IDF dan IndoBERT dalam melakukan retrieval kasus hukum yang relevan dari basis kasus?
4. Bagaimana memanfaatkan putusan terdahulu untuk memprediksi solusi penyelesaian atas kasus baru menggunakan pendekatan Case Solution Reuse?

5. Seberapa efektif sistem CBR yang dibangun dalam hal Accuracy, Precision, Recall, dan F1-Score pada tahap retrieval maupun prediksi?

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Membangun case base dari 40 dokumen putusan Mahkamah Agung Republik Indonesia pada domain perkara penghinaan, fitnah, dan pencemaran nama baik.
2. Merepresentasikan setiap kasus hukum ke dalam struktur data terorganisir yang memuat metadata, ringkasan fakta, dan argumen hukum utama.
3. Mengimplementasikan case retrieval menggunakan dua metode yaitu TF-IDF + Cosine Similarity dan IndoBERT Embedding.
4. Melakukan prediksi solusi kasus baru melalui pendekatan Case Solution Reuse dengan algoritma majority vote dan weighted similarity.
5. Mengevaluasi dan membandingkan performa kedua model retrieval serta performa.

1.4 Ruang Lingkup Penelitian

Penelitian ini memiliki batasan-batasan sebagai berikut:

1. Domain hukum yang digunakan adalah perkara pidana penghinaan, fitnah, dan pencemaran nama baik berdasarkan KUHP (Pasal 310, 311, dan 315).
2. Dataset terdiri dari 40 dokumen putusan yang diunduh dari Direktori Putusan Mahkamah Agung RI.
3. Bahasa pemrograman yang digunakan adalah Python dengan memanfaatkan pustaka pdfminer, pandas, scikit-learn, dan HuggingFace Transformers.
4. Representasi teks menggunakan dua pendekatan: TF-IDF berbasis statistik dan IndoBERT berbasis Transformer.
5. Evaluasi dilakukan menggunakan empat metrik: Accuracy, Precision, Recall, dan F1-Score.
6. Tahap Revise dan Retain pada siklus CBR bersifat opsional dan tidak diimplementasikan pada penelitian ini.

BAB II

TINJAUAN PUSTAKA

2.1 Case-Based Reasoning (CBR)

Case-Based Reasoning (CBR) adalah paradigma pemecahan masalah berbasis kecerdasan buatan yang pertama kali diperkenalkan oleh Roger Schank dan dikembangkan lebih lanjut oleh Janet Kolodner pada awal 1980-an. Aamodt dan Plaza (1994) memberikan definisi komprehensif bahwa CBR adalah metode penalaran yang memecahkan masalah baru dengan mengingat situasi serupa dari masa lalu dan menggunakan kembali informasi atau pengalaman dari situasi tersebut.

Siklus CBR terdiri dari empat tahapan utama yang dikenal dengan model 4R (Aamodt & Plaza, 1994):

- Retrieve: Mencari dan mengambil kasus-kasus yang paling mirip dengan kasus baru dari case base. Proses ini umumnya menggunakan metode pengukuran kemiripan seperti cosine similarity, Euclidean distance, atau k-nearest neighbor.
- Reuse: Menggunakan solusi dari kasus yang sudah diambil untuk memecahkan kasus baru. Solusi dapat digunakan secara langsung (verbatim reuse) atau diadaptasi terlebih dahulu.
- Revise: Menguji solusi yang dihasilkan dan merevisinya apabila diperlukan, berdasarkan evaluasi terhadap solusi yang dihasilkan.
- Retain: Menyimpan kasus baru yang sudah berhasil diselesaikan ke dalam case base untuk digunakan di masa mendatang.

Dalam konteks sistem hukum, CBR memiliki relevansi yang tinggi karena hukum pada dasarnya bekerja berdasarkan preseden. Putusan terdahulu menjadi acuan bagi penyelesaian kasus yang serupa. Pada penelitian ini, tiga dari empat tahapan utama CBR diimplementasikan secara penuh, yaitu Case Representation, Case Retrieval, dan Case Solution Reuse, sedangkan tahap Revise dan Retain bersifat opsional.

2.2 Term Frequency-Inverse Document Frequency (TF-IDF)

TF-IDF adalah metode pembobotan kata yang banyak digunakan dalam sistem Information Retrieval dan Text Mining. Metode ini mengukur tingkat kepentingan suatu kata (term) dalam sebuah dokumen relatif terhadap keseluruhan koleksi dokumen (corpus). Manning et al. (2008) menjelaskan bahwa TF-IDF menggabungkan dua komponen utama, yaitu Term Frequency (TF) yang mengukur seberapa sering sebuah kata muncul dalam suatu dokumen, dan Inverse Document Frequency (IDF) yang mengukur seberapa jarang kata tersebut muncul di seluruh koleksi dokumen. Secara matematis, TF-IDF diformulasikan sebagai berikut:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t)$$

Di mana:

- $\text{TF}(t, d)$ = jumlah kemunculan kata t dalam dokumen d dibagi total kata dalam dokumen d
- $\text{IDF}(t) = \log(N / \text{df}(t))$, di mana N adalah jumlah total dokumen dan $\text{df}(t)$ adalah jumlah dokumen yang mengandung kata t

Kata-kata dengan nilai TF-IDF tinggi cenderung memiliki frekuensi tinggi di dokumen tertentu namun jarang muncul di dokumen lain, sehingga menjadi pembeda yang signifikan. Sebaliknya, kata-kata umum seperti 'yang', 'dan', 'di' akan memiliki nilai TF-IDF rendah karena muncul di hampir semua dokumen (Robertson, 2004). Dalam konteks dokumen hukum, istilah teknis seperti 'dakwaan', 'amar', 'subsidiar', atau nama pasal tertentu cenderung mendapatkan bobot TF-IDF yang tinggi.

2.3 IndoBERT

IndoBERT adalah model bahasa berbasis arsitektur BERT (Bidirectional Encoder Representations from Transformers) yang dikembangkan oleh Devlin et al. (2019) dan diadaptasi khusus untuk Bahasa Indonesia oleh Wilie et al. (2020) dalam proyek IndoNLU (Indonesian Natural Language Understanding). Model yang digunakan dalam penelitian ini adalah indobenchmark/indobert-base-p1 yang tersedia secara publik melalui platform HuggingFace.

IndoBERT dilatih menggunakan korpus Bahasa Indonesia bernama Indo4B yang terdiri dari sekitar 23,4 GB teks berbahasa Indonesia yang dikumpulkan dari berbagai sumber, termasuk artikel berita, Wikipedia Indonesia, dan berbagai dokumen publik lainnya. Dengan pendekatan pre-training berbasis Masked Language Modeling (MLM) dan Next Sentence Prediction (NSP), IndoBERT mampu menghasilkan representasi embedding yang kaya secara semantik dan kontekstual.

Keunggulan utama IndoBERT dibandingkan TF-IDF terletak pada kemampuannya untuk memahami makna kontekstual sebuah kata. Sebagai contoh, kata 'pasal' dalam kalimat 'pasal ini dilanggar' dan 'pasal dalam undang-undang' memiliki representasi vektor yang berbeda di IndoBERT, sementara TF-IDF hanya memperlakukan keduanya sebagai entitas kata yang sama. Hal ini sangat relevan dalam analisis teks hukum yang penuh dengan ambiguitas linguistik.

2.3 Cosine Similarity

Cosine Similarity adalah metrik yang digunakan untuk mengukur kemiripan antara dua vektor berdasarkan sudut yang dibentuk di antara keduanya dalam ruang vektor multidimensi. Metrik ini dirumuskan sebagai:

$$\text{Cosine}(A, B) = (A \cdot B) / (||A|| \times ||B||)$$

Di mana $A \cdot B$ adalah hasil dot product antara vektor A dan B, sedangkan $||A||$ dan $||B||$ adalah norma (panjang) masing-masing vektor. Nilai cosine similarity berada pada rentang 0 hingga 1, di mana nilai 0 berarti kedua vektor sepenuhnya tidak berkorelasi (tegak lurus) dan nilai 1 berarti identik (sejajar).

Cosine Similarity dipilih karena memiliki sifat yang menguntungkan dalam konteks analisis teks: metrik ini tidak terpengaruh oleh panjang dokumen, sehingga dokumen putusan yang sangat panjang dan dokumen yang lebih pendek tetap dapat dibandingkan secara adil. Dalam sistem CBR ini, Cosine Similarity digunakan untuk mengukur kemiripan antara vektor query (kasus baru) dengan vektor setiap kasus dalam case base, baik pada representasi TF-IDF maupun embedding IndoBERT.

2.3 Evaluasi Model: Metrik Klasifikasi

Evaluasi kinerja sistem retrieval dan prediksi dalam penelitian ini menggunakan empat metrik standar dari bidang Information Retrieval dan Machine Learning (Manning et al., 2008), yaitu:

- Accuracy: Proporsi prediksi yang benar terhadap total jumlah prediksi. Memberikan gambaran umum tentang performa model, namun dapat menyesatkan pada dataset tidak seimbang.
- Precision: Proporsi prediksi positif yang benar-benar positif. Mengukur seberapa tepat model dalam mengidentifikasi kasus yang relevan.
- Recall: Proporsi data positif yang berhasil diidentifikasi oleh model. Mengukur kemampuan model untuk menemukan semua kasus yang relevan.
- F1-Score: Rata-rata harmonik antara Precision dan Recall. Memberikan keseimbangan antara kedua metrik tersebut dan berguna ketika terdapat trade-off antara precision dan recall.

BAB III

METODOLOGI PENELITIAN

3.1 Gambaran Umum Sistem

Sistem CBR yang dibangun dalam penelitian ini terdiri dari pipeline end-to-end yang mencakup lima tahap utama sesuai dengan spesifikasi tugas SubCPMK-3. Secara keseluruhan, alur sistem dimulai dari pengumpulan dan pembersihan data (Case Base Building), dilanjutkan dengan representasi kasus (Case Representation), pencarian kasus serupa (Case Retrieval), penggunaan solusi dari kasus terdahulu (Case Solution Reuse), hingga evaluasi kinerja sistem (Model Evaluation).

Seluruh implementasi dilakukan menggunakan bahasa pemrograman Python dengan memanfaatkan ekosistem pustaka yang komprehensif meliputi pdfminer.six untuk konversi PDF, pandas untuk manipulasi data, scikit-learn untuk TF-IDF dan metrik evaluasi, serta HuggingFace Transformers untuk IndoBERT. Eksekusi dilakukan dalam lingkungan Jupyter Notebook untuk memudahkan eksplorasi interaktif dan dokumentasi proses.

3.2 Gambaran Umum Sistem

Dataset yang digunakan dalam penelitian ini adalah 40 dokumen putusan Mahkamah Agung Republik Indonesia pada domain perkara pidana penghinaan, fitnah, dan pencemaran nama baik. Dokumen-dokumen ini diunduh dari Direktori Putusan Mahkamah Agung RI (<https://putusan3.mahkamahagung.go.id>) yang menyediakan akses publik terhadap ribuan dokumen putusan dalam format PDF.

Pemilihan domain ini didasarkan pada beberapa pertimbangan. Pertama, perkara penghinaan, fitnah, dan pencemaran nama baik memiliki pola fakta hukum yang relatif serupa antar kasus sehingga cocok untuk pendekatan CBR. Kedua, ketiga pasal yang relevan (Pasal 310, 311, dan 315 KUHP) memberikan landasan hukum yang jelas sebagai fitur kategorisasi. Ketiga, ketersediaan dokumen dalam direktori MA RI cukup melimpah sehingga memudahkan pengumpulan data minimal 30 dokumen sesuai ketentuan tugas.

3.3 Tahap 1: Case Base Building

3.3.1 Pengumpulan Data (Scraping)

Dokumen putusan diunduh secara langsung dari Direktori Putusan Mahkamah Agung RI. Proses pengunduhan dilakukan dengan mengakses halaman pencarian direktori dengan kata kunci yang relevan seperti

'penghinaan', 'pencemaran nama baik', dan 'fitnah' untuk memfilter putusan pada domain yang dituju. Sebanyak 40 dokumen berhasil diidentifikasi dan diunduh dalam format PDF.

3.3.2 Konversi PDF ke Teks

Setiap dokumen PDF kemudian dikonversi menjadi teks menggunakan pustaka `pdfminer.six` yang mampu mengekstrak teks dari dokumen PDF yang dihasilkan secara digital (bukan dokumen hasil scan). Proses konversi ini menghasilkan file teks mentah yang masih mengandung berbagai artefak dari format PDF, seperti header, footer, nomor halaman, dan karakter-karakter khusus.

3.3.3 Preprocessing Teks

Tahap preprocessing dilakukan untuk membersihkan teks hasil konversi dari noise dan mempersiapkannya untuk tahap representasi. Langkah-langkah preprocessing yang dilakukan meliputi:

- Penghapusan header dan footer: Menghilangkan teks berulang pada bagian atas dan bawah setiap halaman yang merupakan header/footer dokumen pengadilan, seperti nama pengadilan, nomor perkara yang tercetak berulang, dan nomor halaman.
- Normalisasi karakter: Mengubah seluruh teks menjadi huruf kecil (*lowercase*) untuk menghindari duplikasi akibat perbedaan kapitalisasi. Karakter-karakter unicode non-standar juga dinormalisasi ke bentuk ASCII yang setara.
- Penghapusan tanda baca tidak relevan: Menghilangkan tanda baca yang tidak memberikan kontribusi semantik untuk proses retrieval, seperti garis pemisah (-----), tanda bintang (***), dan karakter khusus lainnya.
- Normalisasi whitespace: Menggabungkan spasi ganda dan baris kosong berlebih menjadi satu spasi atau satu baris kosong.

- Validasi keutuhan: Memverifikasi bahwa setiap file teks yang dihasilkan minimal mencakup 80% isi putusan yang diharapkan (minimal terdapat bagian 'Menimbang', 'Mengingat', dan 'Mengadili').

Hasil preprocessing disimpan dalam folder /data/raw/ dengan penamaan case_001.txt hingga case_040.txt. Log pembersihan juga dicatat dalam file /logs/cleaning.log untuk keperluan audit dan reproduksi.

3.4 Tahap 2: Case Representation

3.4.1 Ekstraksi Metadata

Setiap dokumen putusan memiliki struktur yang relatif standar, sehingga ekstraksi metadata dapat dilakukan menggunakan teknik pencocokan pola (pattern matching) berbasis regular expression. Metadata yang diekstrak dari setiap dokumen meliputi:

- case_id: Nomor identifikasi unik yang diberikan secara sekuensial (1-40).\
- filename: Nama file teks yang bersangkutan.
- nomor_perkara: Nomor register perkara di pengadilan, misalnya '123/Pid.B/2022/PN.Mlg'.
- tanggal: Tanggal putusan dijatuhkan.
- pasal: Pasal KUHP yang menjadi dasar dakwaan (310, 311, atau 315).
- pihak: Nama terdakwa dan penuntut umum atau korban.
- ringkasan_fakta: Ekstraksi otomatis bagian 'Menimbang' yang berisi fakta persidangan.
- argumen_hukum: Ekstraksi otomatis bagian 'Mengadili' yang berisi amar putusan.
- panjang_dokumen: Jumlah kata dalam dokumen setelah preprocessing.
- text_full: Teks lengkap dokumen setelah preprocessing.

3.4.2 Feature Engineering

Selain metadata, dilakukan juga feature engineering untuk menghasilkan fitur-fitur tambahan yang berguna dalam proses retrieval:

- Bag-of-Words: Representasi frekuensi kata dari setiap dokumen yang digunakan sebagai fitur dasar.
- Word Count: Jumlah total kata dalam dokumen sebagai indikator panjang putusan.
- Pasal Distribution: Distribusi pasal yang disebut dalam dokumen untuk membantu kategorisasi domain.

Seluruh metadata dan fitur disimpan dalam format CSV pada path `/data/processed/cases.csv` dengan kolom-kolom: `case_id`, `filename`, `no_perkara`, `tanggal`, `pasal`, `pihak`, `ringkasan_fakta`, `argumen_hukum`, `panjang_dokumen`, dan `text_full`. Format ini memudahkan pembacaan dan manipulasi data menggunakan `pandas`.

3.5 Tahap 3: Case Retrieval

3.5.1 Pembagian Data (Data Splitting)

Dataset dibagi menjadi data train dan data test menggunakan fungsi `train_test_split` dari `scikit-learn` dengan rasio 80:20. Dari 40 dokumen yang tersedia, sebanyak 32 dokumen (80%) digunakan sebagai data train untuk membangun representasi vektor case base, sementara 8 dokumen (20%) sisanya digunakan sebagai data test untuk proses evaluasi. Pembagian dilakukan dengan parameter `random_state` yang tetap (fixed seed) untuk memastikan reproduktibilitas hasil.

3.5.2 Pendekatan 1: TF-IDF + Cosine Similarity

Representasi vektor berbasis TF-IDF dibangun menggunakan `TfidfVectorizer` dari `scikit-learn` dengan konfigurasi sebagai berikut:

- `max_features`: 5000 (membatasi pada 5000 kata dengan TF-IDF tertinggi untuk efisiensi komputasi).

- `ngram_range`: (1, 2) (menggunakan unigram dan bigram untuk menangkap frasa hukum yang umum).
- `sublinear_tf`: True (menggunakan logaritma TF untuk mengurangi dominasi kata yang sangat sering muncul).
- `stop_words`: daftar stopwords Bahasa Indonesia dari NLTK yang telah dikustomisasi untuk konteks hukum.

Setelah vektor TF-IDF dibangun, proses retrieval dilakukan dengan menghitung Cosine Similarity antara vektor query (dokumen kasus baru) dengan seluruh vektor dokumen dalam case base (data train). Top-5 dokumen dengan nilai similarity tertinggi kemudian dikembalikan sebagai hasil retrieval.

3.5.3 Pendekatan 2: IndoBERT Embedding

Representasi vektor semantik dibangun menggunakan model IndoBERT (`indobenchmark/indobert-base-p1`) dari HuggingFace. Proses embedding dilakukan dengan langkah-langkah berikut:

- Tokenisasi: Setiap dokumen ditokenisasi menggunakan `IndoBertTokenizer` dengan panjang maksimum 512 token (batas maksimum BERT).
- Truncation: Untuk dokumen yang melebihi 512 token (yang umum pada dokumen putusan panjang), dilakukan pemotongan (truncation) pada bagian yang melebihi batas, dengan prioritas mempertahankan bagian awal dokumen yang umumnya berisi identitas perkara.
- Embedding Ekstraksi: Token [CLS] (token klasifikasi) dari output layer terakhir IndoBERT digunakan sebagai representasi seluruh dokumen, mengikuti konvensi standar penggunaan BERT untuk downstream tasks (Devlin et al., 2019).
- Normalisasi: Vektor embedding dinormalisasi ke unit norm sebelum digunakan dalam perhitungan Cosine Similarity.

Serupa dengan pendekatan TF-IDF, proses retrieval dilakukan dengan menghitung Cosine Similarity antara embedding query dengan seluruh embedding dokumen dalam case base, kemudian mengembalikan top-5 dokumen paling mirip.

3.5.4 Implementasi Fungsi Retrieval

Kedua pendekatan retrieval diimplementasikan dalam satu fungsi terpadu bernama `retrieve()` yang menerima parameter query (teks kasus baru), `k` (jumlah kasus yang dikembalikan, default = 5), dan `method` ('tfidf' atau 'indobert'). Fungsi ini mengembalikan daftar `case_id` beserta skor similarity-nya untuk digunakan pada tahap berikutnya.

3.6 Tahap 4: Case Solution Reuse

Pada tahap ini, sistem memanfaatkan solusi (amar putusan atau pertimbangan hukum) dari top-5 kasus yang paling mirip untuk memprediksi penyelesaian kasus baru. Tahap ini mengimplementasikan fungsi `predict_outcome()` yang menerima teks query dan mengembalikan prediksi solusi.

Dua algoritma prediksi diimplementasikan dan dibandingkan:

- Majority Vote: Memilih solusi yang paling banyak muncul di antara top-5 kasus. Algoritma ini sederhana dan robust, namun tidak mempertimbangkan perbedaan tingkat kemiripan antar kasus.
- Weighted Similarity: Membobot setiap solusi berdasarkan skor similarity-nya. Kasus dengan similarity lebih tinggi mendapat bobot lebih besar dalam penentuan solusi akhir. Algoritma ini lebih akurat secara teoritis namun lebih kompleks.

Solusi yang diekstrak dari setiap kasus mencakup kategori amar putusan (misalnya: 'bersalah - dipidana penjara X bulan/tahun', 'bebas dari dakwaan', atau 'lepas dari tuntutan hukum') serta ringkasan pertimbangan hukum yang relevan. Hasil prediksi disimpan dalam file `/data/results/predictions.csv`.

3.7 Tahap 5: Model Evaluation

Evaluasi dilakukan terhadap kedua komponen utama sistem, yaitu evaluasi retrieval dan evaluasi prediksi, menggunakan fungsi-fungsi dari modul `sklearn.metrics`. Evaluasi retrieval mengukur kemampuan sistem untuk menemukan kasus yang relevan, sedangkan evaluasi prediksi mengukur akurasi sistem dalam memprediksi solusi yang tepat.

Proses evaluasi retrieval dilakukan dengan menyiapkan 8 query uji (sesuai jumlah data test) beserta ground-truth `case_id` yang merupakan kasus yang seharusnya diretrieval. Metrik Accuracy, Precision, Recall, dan F1-Score kemudian dihitung berdasarkan perbandingan antara hasil retrieval sistem dengan ground-truth tersebut.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Statistik Dataset

Tabel 4.1 berikut menyajikan statistik lengkap dataset yang digunakan dalam penelitian ini.

Tabel 4.1 Statistik Dataset Penelitian

Komponen	Nilai
Total Dokumen Putusan	40 dokumen
Domain Hukum	Penghinaan, Fitnah, Pencemaran Nama Baik
Data Train (80%)	32 dokumen
Data Test (20%)	8 dokumen
Sumber Data	Direktori Putusan Mahkamah Agung RI
Format Awal	PDF
Format Setelah Preprocessing	.txt (plain text)